Chatbot ibridi: LLM + Workflow

Prof. Ing. Loris Penserini, PhD

Laboratori Flowise: controllo, rete e supervisione umana

Due tradizioni, due punti di forza

CHATBOT A REGOLE

- percorso prevedibile e ripetibile
- controllo elevato mediante condizioni
- limite: gestisce male ciò che esce dai casi previsti

CHATBOT BASATO SU LLM

- interpreta formulazioni diverse
- genera, riassume, classifica e propone
- limite: l’output non è completamente deterministico

LLM: modello, non applicazione

L’LLM produce una risposta probabile, ma non decide da solo quali dati accettare, chi può inviare richieste, quando spendere credito o cosa pubblicare.

La governance nasce attorno al modello:

- validazione di input e file
- autorizzazioni e ruoli
- controllo del processo
- verifica e revisione dell’output

Il workflow trasforma la risposta in processo

1. Ricezione — testo, immagine, utente
2. Validazione — formato, limiti, permessi
3. Chiamata LLM — prompt, contesto, modello
4. Controllo — esito, stato, revisione
5. Azione — pubblicazione, archiviazione o rifiuto

Le fasi deterministiche restano programmabili con condizioni e routine tradizionali.

Human-in-the-loop

UTENTE

Formula una domanda o propone un contenuto.

WORKFLOW + LLM

Elaborano una bozza e registrano lo stato del processo.

DOCENTE / REVISORE

Approva, modifica o rifiuta prima della pubblicazione.

La supervisione umana è una fase prevista dall’architettura, non una correzione occasionale.

Le routine tradizionali governano l’AI

- IF–THEN–ELSE: blocca i casi non ammessi
- Validazione: controlla formato, dimensione e campi obbligatori
- Stati: in attesa → elaborazione → revisione → pubblicazione
- Autorizzazione: limita funzioni e postazioni
- Controllo costi: abilita la chiamata a pagamento solo quando serve
- Fallback: gestisce errore, timeout o modello non disponibile

Controllo prima, durante e dopo l’AI

PRIMA

Autenticare; validare l’input; definire i limiti.

DURANTE

Costruire il prompt; gestire memoria e stato; applicare timeout.

DOPO

Verificare l’esito; revisionare; pubblicare o scartare.

Il workflow rende osservabili decisioni e stati, non soltanto la risposta finale.

Due laboratori, lo stesso principio

LAB 1 — OLLAMA REMOTO

Flowise usa nella LAN un modello locale installato su un secondo PC.

Obiettivo: comprendere dove risiede il modello e come viaggia la richiesta.

LAB 2 — OPENAI + IMMAGINI

PlantPhoto invia fotografie di piante a un modello OpenAI multimodale a pagamento.

Obiettivo: applicare autorizzazione docente, controllo dei costi e revisione umana.

Generazione controllata

LLM + WORKFLOW + PERSONA

L’LLM interpreta e genera.

Il workflow decide il percorso.

La persona supervisiona le scelte.

Un chatbot affidabile è un sistema software completo: il modello è un componente, non il controllore assoluto.

Esperimento 1: Ollama remoto

Scenario didattico

Flowise è eseguito sul PC principale. Ollama e il modello LLM risiedono su un secondo PC della stessa rete locale.

La separazione obbliga a distinguere chiaramente:

- applicazione che orchestra il workflow
- servizio che esegue l’inferenza
- indirizzo IP e porta usati per comunicare

Architettura di rete: Ollama remoto

PC 1 — FLOWISE

• browser e interfaccia di progettazione

• server Flowise: http://127.0.0.1:3000

• workflow e nodo che chiama il modello

RETE LOCALE

• collega i due PC tramite Ethernet o Wi-Fi

• la richiesta usa HTTP verso l'IPv4 del PC 2

PC 2 — OLLAMA

• servizio in ascolto sulla porta TCP 11434

• modello LLM memorizzato ed eseguito localmente

Dove risiedono applicazioni, dati e modello

PC 1

1. Browser dell’utente
2. Applicazione Flowise
3. Definizione del workflow e configurazione della connessione

PC 2

4. Servizio Ollama
5. File del modello e motore di inferenza

La risposta attraversa nuovamente la LAN e torna a Flowise; non viene elaborata da un servizio cloud.

Configurare il PC Ollama

1. Installare Ollama e scaricare il modello scelto.
2. Verificare localmente che il modello risponda.
3. Individuare l’indirizzo IPv4 della scheda di rete attiva.
4. Rendere Ollama raggiungibile dalla LAN, mantenendo la porta predefinita 11434.
5. Consentire nel firewall soltanto il traffico necessario e solo sulla rete prevista.
6. Annotare l’URL: http://IP_DEL_PC_OLLAMA:11434

L’indirizzo può cambiare passando dalla rete di casa a quella dell’aula.

Configurare Flowise

Nel nodo Ollama di Flowise si impostano:

- Base URL: http://IP_DEL_PC_OLLAMA:11434
- nome esatto del modello già installato sul PC 2
- parametri di generazione utili al laboratorio

Prima del workflow completo conviene verificare tre livelli:

1. raggiungibilità IP del PC 2
2. raggiungibilità della porta 11434
3. risposta del modello attraverso Flowise

Ollama locale non richiede una chiave OpenAI.

Percorso completo di una richiesta

1. L’utente inserisce il prompt nel browser.
2. Flowise riceve l’input e avvia il workflow.
3. Le routine deterministiche validano dati e stato.
4. Il nodo Ollama invia la richiesta a http://IP_PC2:11434.
5. Ollama esegue il modello sul PC 2.
6. La risposta torna a Flowise attraverso la LAN.
7. Il workflow controlla l’esito e decide la fase successiva.
8. Il browser mostra il risultato finale.

Collaudo e passaggio al cloud

TEST MINIMI

- i due PC appartengono alla stessa rete raggiungibile
- Ollama risponde localmente sul PC 2
- il PC 1 raggiunge IP e porta 11434
- Flowise usa il Base URL e il nome modello corretti
- il workflow gestisce anche timeout ed errore

Nel secondo esperimento sostituiremo il modello locale con OpenAI e aggiungeremo immagini, chiave API, credito a consumo e approvazione docente prima della chiamata AI.