Prof. Ing. Loris Penserini, PhD
Modello locale su un secondo PC

Flowise + Ollama:

laboratorio visuale

Architettura del laboratorio Ollama

PC 1 — FLOWISE

- browser e editor visuale su http://127.0.0.1:3000
- Chatflow Test_Ollama
- richiesta HTTP verso il secondo PC

PC 2 — OLLAMA

- servizio esposto nella LAN sulla porta TCP 11434
- modello llama3.1:latest eseguito localmente

La domanda e la risposta attraversano la rete locale. Non viene usato un servizio cloud e non è necessaria una chiave OpenAI.

Preparare il PC che ospita Ollama

1. Avviare Ollama sul secondo PC.
2. Verificare che llama3.1:latest sia installato.
3. Abilitare Expose Ollama to the network.
4. Leggere l’IPv4 dell’interfaccia realmente connessa.
5. Tenere entrambi i PC nella stessa LAN raggiungibile.
6. Dal PC Flowise verificare http://IP_OLLAMA:11434/api/tags.

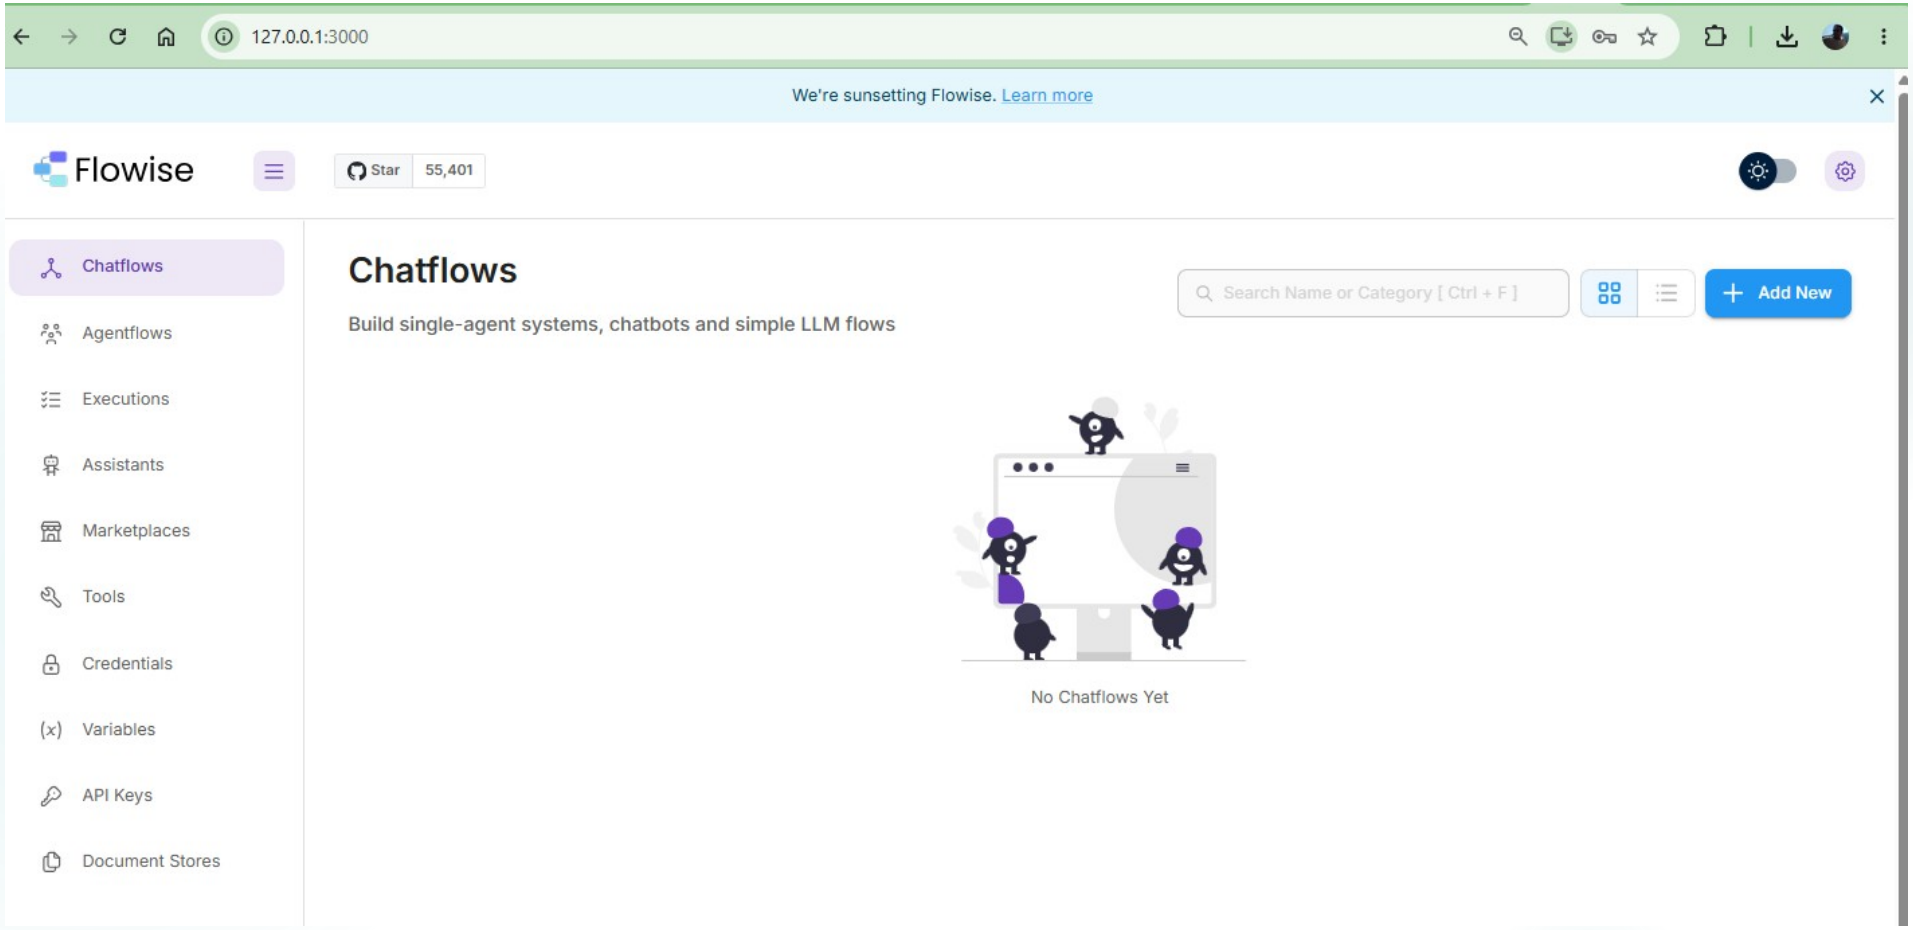
Nel collaudo domestico l’indirizzo era 192.168.1.94. È un dato della sessione, non un valore da riutilizzare automaticamente in aula.

Verifica dell’API Ollama: /api/tags

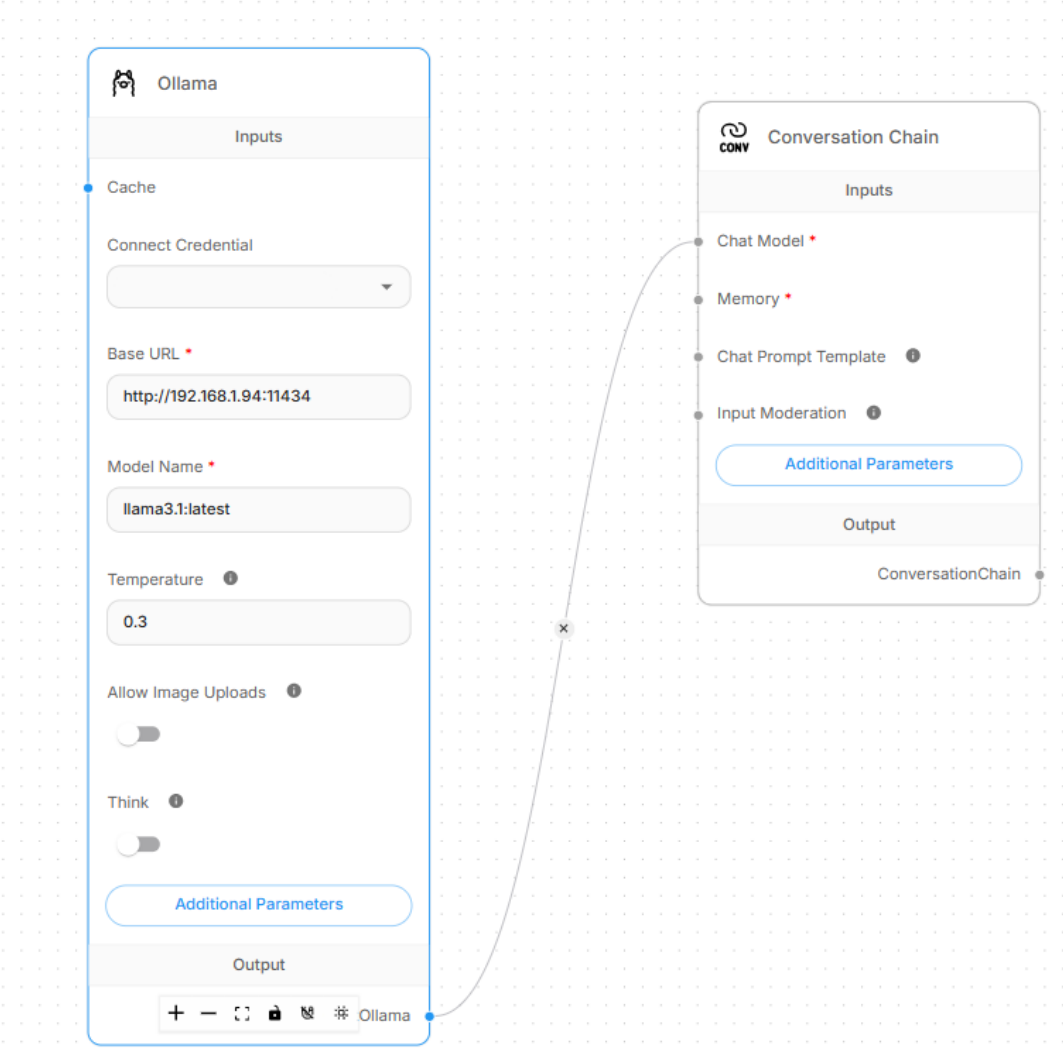
Pretty-print

{"models":[{"name":"llama3.1:latest","model":"llama3.1:latest","modified_at":"2025-06-18T10:14:38.8539227+02:00","size":4920753328,"digest":"46e0c10c039e019119339687c3c1757cc81b9da49709a3b3924863ba87ca666e","details":
{"parent_model":"","format":"gguf","family":"llama","families":["llama"],"parameter_size":"8.0B","quantization_level":"Q4_K_M","context_length":131072,"embedding_length":4096},"capabilities":["completion","tools"]}]}

Flowise: creare il Chatflow Test_Ollama



Primo collegamento: ChatOllama e catena



Configurare i nodi visuali

CHATOLLAMA

- Base URL: http://IP_OLLAMA:11434
- Model Name: llama3.1:latest
- Temperature: 0.3
- credenziale vuota nel test locale

CONVERSATION CHAIN

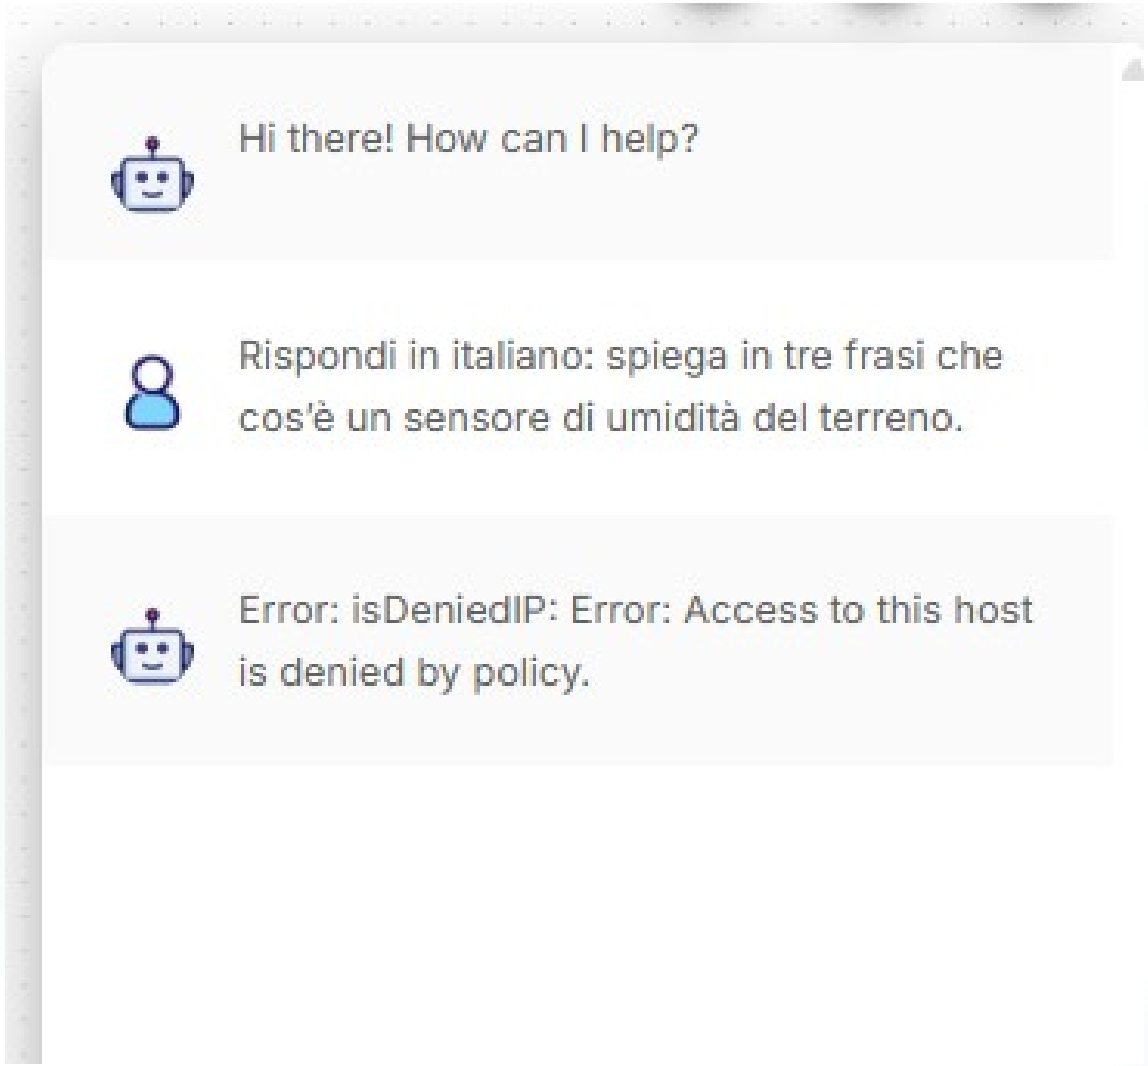
Riceve ChatOllama nell’ingresso Chat Model.

BUFFER MEMORY

Va aggiunto e collegato all’ingresso Memory della catena.

localhost non va usato per Ollama: indicherebbe il PC Flowise, non il secondo computer.

Primo test: richiesta bloccata da Flowise



Perché compare isDeniedIP

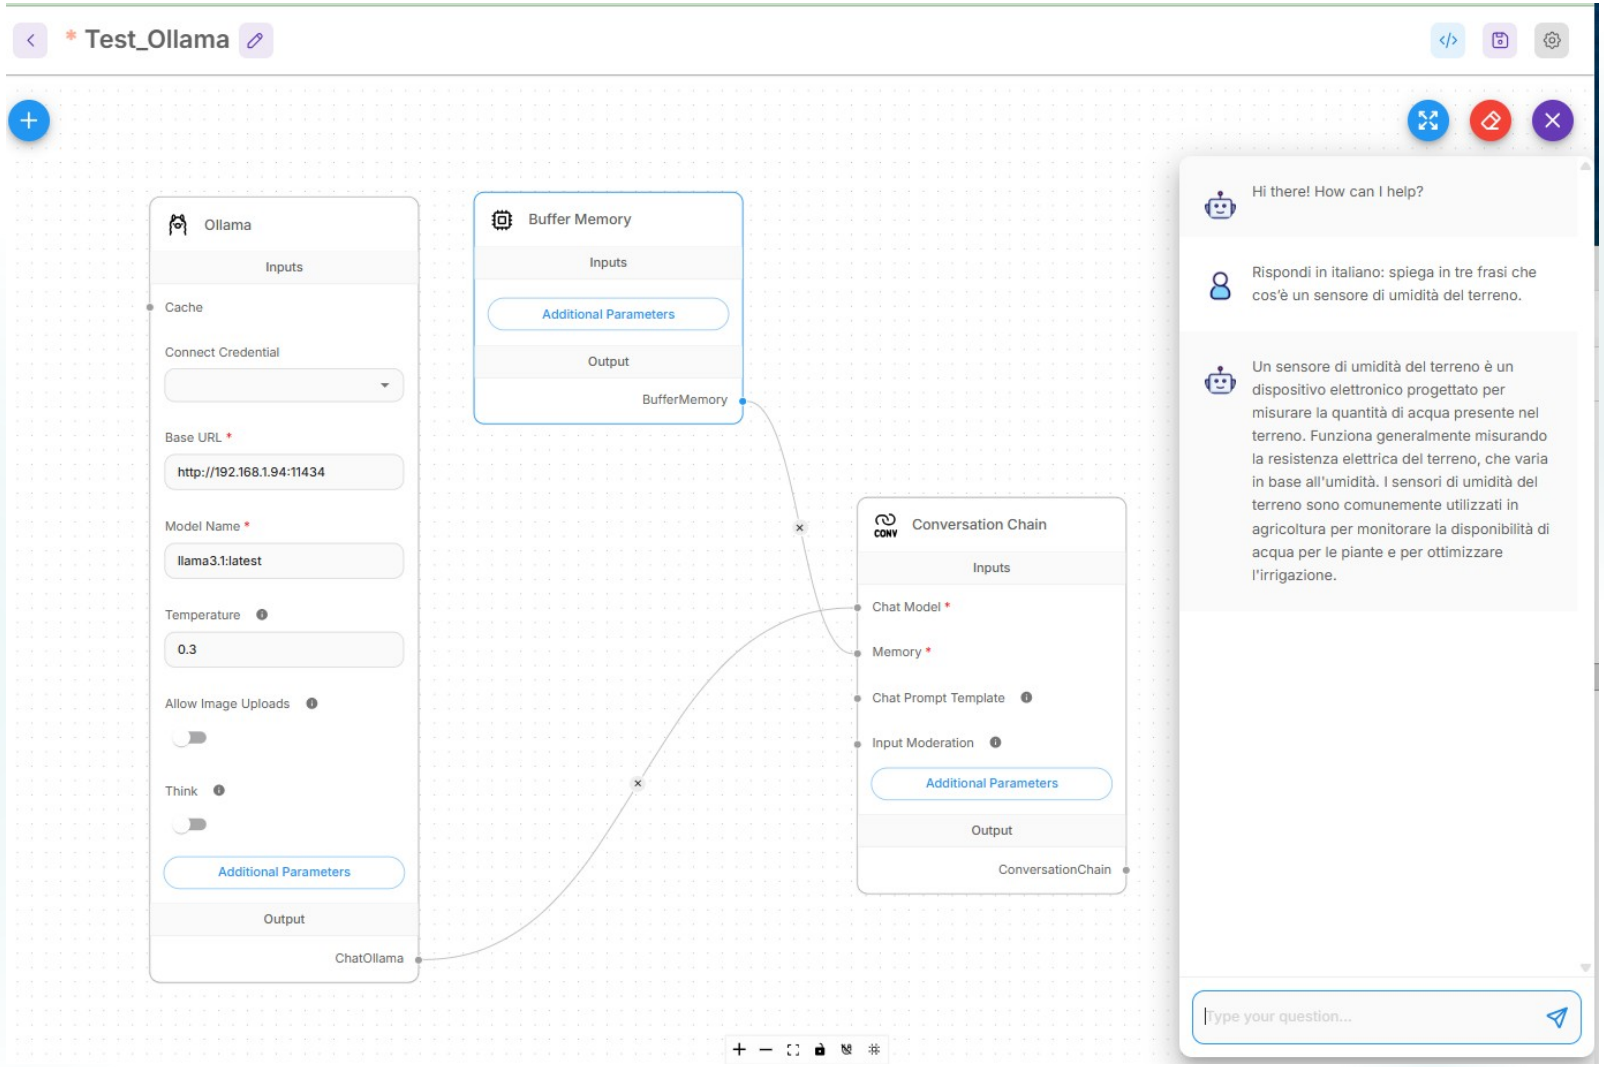
L’API /api/tags rispondeva già: Ollama, rete e porta erano operativi. La richiesta veniva fermata da Flowise prima di raggiungere il modello.

Flowise applica una policy HTTP contro destinazioni private e potenzialmente pericolose. Nel laboratorio il BAT è stato configurato per:

- disabilitare la lista automatica
- ricostruire i blocchi necessari
- sottrarre soltanto l’IPv4 del PC Ollama

L’eccezione è limitata al contesto del laboratorio e non sostituisce il firewall Windows.

Chatflow completo e risposta del modello



Che cosa dimostra il collaudo

DIMOSTRA

- Flowise avviato e accessibile localmente
- PC Ollama raggiungibile sulla porta 11434
- modello llama3.1:latest disponibile
- nodi collegati e inizializzati
- richiesta e risposta attraverso la LAN

NON DIMOSTRA

- correttezza assoluta dei contenuti generati
- prestazioni, throughput o consumo di memoria
- funzionamento di tutti i nodi Flowise
- analisi delle immagini: il modello usato in questo test era testuale

Dal modello locale al servizio cloud

OLLAMA REMOTO

- modello e calcolo sul PC 2
- nessun costo per singola chiamata API
- prestazioni dipendenti dall’hardware locale
- comunicazione confinata alla LAN

OPENAI NEL PROGETTO PLANTPHOTO

- modello multimodale nel cloud
- chiave API e credito a consumo
- fotografie fuori dalla rete locale
- controllo docente prima della chiamata

Flowise mantiene lo stesso ruolo: orchestrare componenti e inserire controlli attorno al modello.